Florian GRIMA

Lyon • +33 7 75 72 41 84 • floriangrimadev@gmail.com • linkedin.com/in/florian-grima

Ingénieur IA

Ingénieur IA diplômé d'Epitech (niveau 7), spécialisé dans les applications d'IA générative en production : RAG (LlamaIndex, pgvector), orchestration d'agents et fine-tuning de Stable Diffusion (LoRA). Fort de plus de 3 ans d'expérience fullstack (TypeScript, Python, AWS), je relie les modèles aux produits. Auteur d'Energizer, projet de recherche open source sur l'Apple Neural Engine.

EXPÉRIENCES

Eclat **12/2025 - Present**

eclats.shop

Co-fondateur & Ingénieur IA Fullstack **Lyon, France**

Projet entrepreneurial

- Conçu l'architecture d'un workflow de personnalisation de bijoux 3D en B2B, connecté aux API de fabrication industrielle de Materialise.
- Développé un moteur de tarification intégrant les cours des métaux précieux en temps réel et le seuil de commande minimum de 50 € imposé par les fournisseurs.
- Livré une plateforme web (React, Three.js, NestJS) avec rendu 3D procédural sous Blender, taux de conversion des formulaires passé de 5 % à 30 % lors du test initial (100 visiteurs).
- Fine-tuné Stable Diffusion (LoRA) sur 1 000 images de bagues annotées et nettoyées, génération d'images à partir d'une demande client en langage naturel, interprétée par un LLM, en 10 à 15 secondes.

TAKER **01/2026 - 08/2026**

Consultant IA - Mission **Lyon, France**

Missions de conseil réalisées en parallèle de ma dernière année à Epitech.

- Conçu et déployé un assistant RAG interne connecté à la base Notion de l'entreprise (50 pages, 15 utilisateurs), réduisant le temps de recherche de 25%. Stack : FastAPI, Python, Next.js, LlamaIndex, pgvector, Docker.
- Mis en place Hermes Agent, un orchestrateur d'agents IA open source, pour automatiser la production de contenu du pôle communication.

EPITECH **09/2025 - 08/2026**

Accompagnateur Pédagogique • Internship **Lyon, France**

- Évalué et noté les projets d'IA de 4 promotions (C, C++, Python, Node.js, PyTorch) sur une année.
- Conçu et animé un programme d'ateliers hebdomadaires de 2 h sur l'IA (Python, PyTorch), pour 15 étudiants, afin de rendre accessibles les concepts avancés.

Bulltribe **09/2024 - 03/2025**

Ingénieur Fullstack • Freelancer **À distance**

- Migré plus de 20 000 lignes d'endpoints backend de JavaScript vers TypeScript, avec une nouvelle architecture: baisse de 60 % des bugs en production mesuré par Sentry.
- Refondu l'interface de l'application mobile pour améliorer la lisibilité et le parcours utilisateur, validé par des tests end-to-end et les retours des clients.

Gamercraft **07/2022 - 05/2024**

Ingénieur Fullstack **Marseille, France**

- Mis en production un système de paris en temps réel synchronisé avec le live Twitch des joueurs (1 000 utilisateurs).

- Automatisé sur AWS la création des tournois de jeux vidéo (≈10 par jour), réduisant le temps de mise en place de 25 %.

EDUCATION

Diplôme d'Expert en technologies de l'information + Titre d'Expert en ingénierie logicielle enregistré au RNCP niveau 7
Epitech — Marseille et Paris • 09/2021 - 08/2026

Année à l'étranger durant la 4e année
Université Laval — Québec City • 09/2024 - 05/2025

PROJETS

Energizer — 12/2025 - Present
Projet de recherche open source (MIT) https://energizer-ml.github.io/energizer - pip install energizer

Conçu une bibliothèque de deep learning en Python (autograd, couches, optimiseurs ; backends NumPy et MLX/Metal) et un banc de mesure pour caractériser l'Apple Neural Engine (M4 Pro) : placement des opérations, latence, consommation.
Mesuré 72 charges de travail et montré que l'ANE est un moteur d'inférence efficace et non un accélérateur d'entraînement (rafraîchissement des poids Core ML > 200× le coût d'un pas MLX), mais 2,1 à 2,4× plus rapide et 10 à 11× moins énergivore sur tronc gelé.

LibrOpen - Projet de fin d'études — 09/2024 - 06/2026
Conception d'une application web pour gagner de la visibilité sur ses projets personnels.
Next.js / Typescript / AdonisJS / Postgresql / Python

R-Type - Jeu en réseau C++
Création d'un jeu de zéro en C++ en ligne.
C++

SKILLS

Langues: Anglais (C1), Espagnol (B1), Français (natif)

IA / ML: Apple Neural Engine, Core ML, Hermes Agent, LlamaIndex, Metal, MLX, NumPy, orchestration d' agents, pgvector, PyTorch, RAG, Stable Diffusion (fine-tuning)

Backend: AdonisJS, FastAPI, NestJS, Node.js, PostgreSQL, Python, SQL

Front-end: JavaScript, Next.js, React, Three.js, TypeScript

Cloud / DevOps: AWS, Docker

Autres langages: C, C#, C++, Rust